

In questa sezione verranno analizzati i principali strumenti di rilevazione del plagio del codice sorgente (SCDP) sviluppati nel corso degli anni. La rassegna si concentra sulle soluzioni accademiche e open source che hanno definito lo standard del settore, per poi esplorare piattaforme commerciali più recenti. Ogni strumento verrà valutato in base alle tecniche algoritmiche adottate (discusse nel Capitolo 3), ai linguaggi supportati e alla robustezza contro le tecniche di offuscamento.

Strumenti Accademici e Open Source

Il panorama degli strumenti accademici è dominato da soluzioni storiche che, nonostante l'età, rimangono i punti di riferimento per l'analisi statica del plagio. Questi tool sono tipicamente gratuiti per uso educativo e si basano su analisi testuale o token-based

MOSS (Measure Of Software Similarity)¹

Sviluppato nel 1997 all'Università di Stanford, MOSS è probabilmente lo strumento di rilevazione del plagio più diffuso a livello accademico.

MOSS utilizza un approccio basato sui token. Dopo aver effettuato una procedura di *lexing* sul codice e rimosso spazi e commenti, lo strumento non utilizza algoritmi di string matching completi (come GST), ma implementa una tecnica proprietaria basata sul **Winnowing** (Document Fingerprinting). Il codice viene diviso in *k-grammi* di token; di questi viene calcolato l'hash e solo un sottoinsieme selezionato (la fingerprint) viene memorizzato e confrontato.

Questo approccio rende MOSS estremamente scalabile e veloce, permettendo di confrontare migliaia di file in pochi secondi. È robusto contro l'offuscamento lessicale (renaming) e il riordinamento del codice, poiché le "impronte" sono invarianti rispetto alla posizione. Un numero molto vasto di linguaggi è supportato da MOSS, tra questi C, C++, Java e Python.

MOSS viene fornito come servizio online (tramite script di invio al server di Stanford) e non è open-source. Inoltre, come tutti i sistemi token-based, può essere ingannato da pesanti modifiche strutturali o dall'inserimento massiccio di codice "rumore" che altera i *k-grammi*. Inoltre, studi recenti hanno rilevato una grave criticità legata all'Intelligenza Artificiale generativa: MOSS può essere facilmente eluso utilizzando LLM pre-addestrati. È stato dimostrato, ad esempio, che studenti che utilizzano modelli come GPT-J per completare assegnamenti di programmazione introduttiva riescono a bypassare completamente i controlli di MOSS. Questo accade poiché il codice generato da tali modelli risulta sufficientemente diversificato nella struttura e manca di quei "segnali" tipici che i sistemi algoritmici tradizionali utilizzano per identificare il plagio manuale.

JPlag

SIM

Sherlock

CodeMatch

Plaggie

Codequiry

Strumenti Commerciali e Piattaforme Integrate

Tabella Comparativa degli Strumenti

¹<https://theory.stanford.edu/~aiken/moss/>